

## OpenAI Platform

# Tokenizador

### Aprenda sobre tokenização de modelos de linguagem

Os grandes modelos de linguagem da OpenAI processam texto usando **tokens**, que são sequências comuns de caracteres encontradas em um conjunto de texto. Os modelos aprendem a entender as relações estatísticas entre esses tokens e se destacam na produção do próximo token em uma sequência. [Saber mais](#).

Você pode usar a ferramenta abaixo para entender como um trecho de texto pode ser tokenizado por um modelo de linguagem e a contagem total de tokens nesse trecho de texto.

**GPT-5.x e O1/3**

GPT-4 e GPT-3.5 (legado)

GPT-3 (legado)

Jose Guilherme Behrmann Barros , "A engenharia de prompt otimiza LLMs"

Claro

Mostrar exemplo

**Fichas****20****Personagens****70**

JoséCulpaHermeSerhorahomemBarros, "UMengenhariadeincitarotimizaLLMs"

**Texto**

IDs de token

Uma regra prática útil é que um token geralmente corresponde a cerca de 4 caracteres de texto em inglês comum. Isso se traduz em aproximadamente  $\frac{3}{4}$  de uma palavra (portanto, 100

tokens são aproximadamente 75 palavras).

Se você precisa de uma interface programática para tokenizar texto, confira nossa solução. [token do tiktoken](#) pacote para Python. Para JavaScript, o pacote com suporte da comunidade. [@dbdq/tiktoken](#) O pacote funciona com a maioria dos modelos GPT.